

# Amazon reviews

## Vukašin Kalaba RA44/2021

### 1) Opis skupa podataka (tema, datoteke, broj zapisa...)

Odabrao sam skup podataka **Amazon Reviews** sa Kaggle sajta. Tema skupa podataka je analiza recenzija korisnika o proizvodima kupljenim putem Amazon platforme. Skup se sastoji od jedne glavne datoteke koja sadrži veliki broj zapisa (više od milion recenzija). Svaki zapis predstavlja jednu recenziju, sa svim pratećim informacijama kao što su ocena, datum, tekst recenzije, korisnički ID i informacije o proizvodu.

### 2. Semantika postojećih kolona

U datoteci se nalaze sledeće kolone:

- **Id** – jedinstveni identifikator zapisa.
- **ProductId** – jedinstveni identifikator proizvoda na Amazonu.
- **UserId** – jedinstveni identifikator korisnika koji je ostavio recenziju.
- **ProfileName** – ime profila korisnika.
- **HelpfulnessNumerator** – broj korisnika koji su označili recenziju kao korisnu.
- **HelpfulnessDenominator** – broj korisnika koji su glasali o korisnosti recenzije.
- **Score** – numerička ocena proizvoda (od 1 do 5 zvezdica).
- **Time** – vremenska oznaka kada je recenzija postavljena (UNIX timestamp).
- **Summary** – kratak opis recenzije koji korisnik unosi.
- **Text** – glavni tekst recenzije sa detaljima mišljenja korisnika.

### 3. Primer prostiranja podataka kroz datoteke

Na primer, ako posmatram jedan zapis:

- ProductId: B001E4KFG0
- UserId: A3SGXH7AUHU8GW

- ProfileName: "delmartian"
- HelpfulnessNumerator: 1
- HelpfulnessDenominator: 1
- Score: 5
- Time: 1303862400
- Summary: "Good Quality Dog Food"
- Text: "I have bought several of the Vitality canned dog food products and have found them all to be of good quality..."

Iz ovoga se vidi kako se informacije o jednom proizvodu i recenziji čuvaju u okviru jednog zapisa. Ako gledam više datoteka, svaka sadrži isti tip strukture, samo različite recenzije.

#### 4. Predlog logičke sheme baze podataka — dokumentno-orijentisana baza

```
{
  "review_id": "UUID",
  "product": {
    "product_id": "string",
    "name": "string"
  },
  "user": {
    "user_id": "string",
    "profile_name": "string"
  },
  "review": {
    "score": "int",
    "helpfulness": {
      "numerator": "int",
      "denominator": "int"
    }
  }
}
```

```
},  
"summary": "string",  
"text": "string",  
"time": "date"  
}  
}
```

## **5. Program za prebacivanje podataka u bazu**

Planiram da napišem program u Pythonu koji će čitati originalne CSV fajlove pomoću biblioteka kao što su pandas ili csv, i zatim prebacivati podatke u MongoDB koristeći biblioteku pymongo. Tokom prebacivanja podaci će biti transformisani tako da odgovaraju gorenavedenoj logičkoj šemi.

## **6. Predlog agregacija nad podacima**

### **Složenija pitanja:**

1. Postoji li korelacija između dužine teksta recenzije i korisnosti recenzije
2. Kako se menjao broj pozitivnih recenzija tokom godina za određene kategorije proizvoda
3. Da li korisnici koji ostavljaju duže recenzije imaju veći uticaj (veći HelpfulnessNumerator/Denominator)
4. Koji proizvodi imaju najveću razliku između prosečne ocene i prosečne korisnosti recenzija
5. Da li postoji sezonski efekat (npr. rast broja recenzija u decembru za određene proizvode)