

US Wildfire Dataset

Vukašin Kalaba RA44/2021

1) Opis skupa podataka (tema, datoteke, broj zapisa...)

Odabrani skup podataka sa Kaggle sajta je **US Wildfire Dataset**. Tema skupa podataka je analiza šumskih požara na teritoriji Sjedinjenih Američkih Država. Skup se sastoji od više datoteka u CSV formatu koje zajedno zauzimaju više od 100 MB. U njima se nalazi nekoliko miliona zapisa o pojedinačnim požarima u periodu od više decenija. Svaki zapis predstavlja jedan požar sa informacijama o njegovom mestu, vremenu, uzroku, veličini i statusu.

2. Semantika postojećih kolona

U datasetu se nalaze sledeće ključne kolone:

FOD_ID – jedinstveni identifikator požara.

FIRE_YEAR – godina kada je požar zabeležen.

DISCOVERY_DATE – datum kada je požar otkriven.

DISCOVERY_DOY – redni broj dana u godini kada je otkriven požar.

STAT_CAUSE_CODE – kod koji označava uzrok požara.

STAT_CAUSE_DESCR – opis uzroka (npr. munja, ljudska nepažnja, podmetnut).

FIRE_SIZE – veličina požara izražena u akrima.

FIRE_SIZE_CLASS – klasifikacija požara po veličini (A–G).

LATITUDE i LONGITUDE – geografske koordinate.

STATE – savezna država u kojoj je požar nastao.

FIPS_CODE – šifra okruga.

OWNER_CODE i OWNER_DESCR – tip vlasništva zemljišta (federalno, privatno, plemensko itd.).

CONT_DATE – datum kada je požar stavljen pod kontrolu.

3. Primer prostiranja podataka kroz datoteke

Na primer, ako posmatram jedan zapis:

FOD_ID: 123456

FIRE_YEAR: 2017

DISCOVERY_DATE: 2017-08-10

STAT_CAUSE_DESCR: "Lightning"

FIRE_SIZE: 250.5

FIRE_SIZE_CLASS: C

STATE: "CA"

LATITUDE: 38.123

LONGITUDE: -120.456

OWNER_DESCR: "Private"

Ovaj primer pokazuje kako se informacije o jednom konkretnom požaru (gde je nastao, kada, koji je uzrok i kolika je bila površina) nalaze u jednom zapisu.

4. Predlog logičke sheme baze podataka — dokumentno-orijentisana baza

```
{  
  "fire_id": "UUID",  
  "location": {  
    "state": "string",  
    "county_code": "string",  
    "latitude": "double",  
    "longitude": "double"  
  },  
  "date": {  
    "year": "int",  
    "discovery": "date",
```

```
"contained": "date"
},
"cause": {
  "code": "int",
  "description": "string"
},
"size": {
  "acres": "double",
  "class": "string"
},
"ownership": {
  "code": "int",
  "description": "string"
}
}
```

5. Program za prebacivanje podataka u bazu

Planiram da napišem program u Pythonu koristeći pandas za čitanje CSV fajlova i pymongo za prebacivanje u MongoDB. Tokom učitavanja, podaci će biti transformisani u JSON dokumente prema gore navedenoj šemi.

6. Predlog agregacija nad podacima

Složenija pitanja:

1. Koji su najčešći uzroci požara u svakoj saveznoj državi i kako se njihova učestalost menjala kroz decenije?
2. Da li postoji sezonski obrazac izbijanja požara (meseci/godišnja doba) i kako varira u različitim klimatskim regionima SAD-a?
3. Koja je povezanost između tipa vlasništva zemljišta (federalno, privatno, plemensko) i prosečne veličine požara?

4. Koje države imaju najveći broj požara po jedinici površine i da li se trend menjao kroz vreme?
5. Da li postoji korelacija između uzroka požara (npr. munja vs. ljudski faktor) i prosečnog trajanja do stavljanja požara pod kontrolu?